新型冠状病毒数据分析演示

新型冠状病毒（2019-nCov) 的疫情牵动着全世界人民的心，而理性地对待离不开数据和分析。为了让人民大众及时了解情况，很多网站都公布疫情的实时信息。比方说丁香园疫情实时动态 (https://ncov.dxy.cn/ncovh5/view/pneumonia)， 腾讯疫情实时追踪 (https://news.qq.com/zt2020/page/feiyan.htm) 等等。这些网站的内容都是一样的，它们快速地为公众提供了信息，增加了透明度。但是如果读者希望对疫情有进一步的了解，这些网站就不够用了。比方说，如果你想得到过去十天湖北省确诊人数，那就只能从趋势图上作个估计了。再比方说，如果你想对比一下湖南、广东、浙江三省在过去十天的新增确诊人数，那么单凭网页数据也无能为力了。

为了取得可以供研究使用的数据，DXY-2019-nCoV-Data (https://github.com/BlankerL/DXY-2019-nCoV-Data) 项目利用网络爬虫不断从网上抓取数据，更新并存成 CSV 格式。然而，这个 CSV 文件包含的是不同时刻网页上的信息片段，有的时候只有这几个城市，有的时候只有那几个城市，数据并不规整。

为了进一步方便用户进行研究，本项目nCov2019_analysis (https://github.com/jianxu305/nCov2019_analysis) 提供了一些基本工具，把实时数据规整为每日数据，方便用户按时间、省份、城市等方法检索。同时，本项目还提供了基本的时间序列和横向分析作图函数，方便用户取得基本信息。

以下是基本使用方法演示：

In [112]:
```
import pandas as pd
import matplotlib.pyplot as plt
import utils   # some convenient functions

%load_ext autoreload
%autoreload 2
```

```
The autoreload extension is already loaded. To reload it, use:
  %reload_ext autoreload
```

1. 获取原始 CSV 数据

In [113]:
```
data = utils.load_chinese_data()
```

```
最近更新于:  2020-02-09 13:33:40.433000
数据日期范围:  2020-01-24 to 2020-02-09
数据条目数:  27138
```

In [114]:
```
data.head(3)  # 查看数据形式
```

Out[114]:

	provinceName	cityName	province_confirmedCount	province_suspectedCount	province_curedC
0	河南省	信阳	1033	0	
1	河南省	南阳	1033	0	
2	河南省	郑州	1033	0	

2. 把实时数据整合成每日数据

In [115]:
```
daily_frm = utils.aggDaily(data, clean_data=True)
```

In [116]:
```
daily_frm.tail(3)
```

Out[116]:

	provinceName	cityName	confirmed	cured	dead	updateTime	updateDate
778	黑龙江省	鹤岗	4	0	0	2020-02-09 08:55:45.123	2020-02-09
780	黑龙江省	黑河	2	0	0	2020-02-09 08:55:45.123	2020-02-09
773	黑龙江省	齐齐哈尔	27	0	0	2020-02-09 08:55:45.123	2020-02-09

3. 数据查看

3.1 提取部分信息

用 **provinceName** 检索省级数据

In [117]:
```
daily_frm[daily_frm['provinceName'] == '广东省']
```

Out[117]:

	provinceName	cityName	confirmed	cured	dead	updateTime	updateDate
26159	广东省	中山	2	0	0	2020-01-24 23:35:03.158	2020-01-24
26153	广东省	佛山	7	0	0	2020-01-24 23:35:03.158	2020-01-24
26154	广东省	广州	7	0	0	2020-01-24 23:35:03.158	2020-01-24
26155	广东省	惠州	5	0	0	2020-01-24 23:35:03.158	2020-01-24
26151	广东省	深圳	15	2	0	2020-01-24 23:35:03.158	2020-01-24
...	...	...	...	...	...	...	...
90	广东省	珠海	83	4	0	2020-02-09 13:22:30.367	2020-02-09
98	广东省	肇庆	14	3	1	2020-02-09 13:22:30.367	2020-02-09
102	广东省	茂名	9	1	0	2020-02-09 13:22:30.367	2020-02-09
99	广东省	阳江	13	1	0	2020-02-09 13:22:30.367	2020-02-09
104	广东省	韶关	6	2	0	2020-02-09 13:22:30.367	2020-02-09

314 rows × 7 columns

用 **cityName** 检索市级数据

In [118]:
```
daily_frm[daily_frm['cityName'] == '武汉']
```

Out[118]:

	provinceName	cityName	confirmed	cured	dead	updateTime	updateDate
26350	湖北省	武汉	495	31	23	2020-01-24 17:30:09.978	2020-01-24
25175	湖北省	武汉	572	32	38	2020-01-25 23:55:35.775	2020-01-25
24526	湖北省	武汉	618	40	45	2020-01-26 13:50:35.848	2020-01-26
23347	湖北省	武汉	698	42	63	2020-01-27 16:42:57.343	2020-01-27
22543	湖北省	武汉	1590	47	85	2020-01-28 16:36:17.441	2020-01-28
21349	湖北省	武汉	1905	54	104	2020-01-29 20:34:44.154	2020-01-29
20170	湖北省	武汉	2261	54	129	2020-01-30 22:24:37.371	2020-01-30
18530	湖北省	武汉	2639	103	159	2020-01-31 22:06:41.473	2020-01-31
16239	湖北省	武汉	3215	106	192	2020-02-01 19:49:55.626	2020-02-01
14366	湖北省	武汉	4109	175	224	2020-02-02 20:50:05.247	2020-02-02
12700	湖北省	武汉	5142	228	265	2020-02-03 21:32:30.697	2020-02-03
11458	湖北省	武汉	6384	306	313	2020-02-04 17:34:45.960	2020-02-04
8632	湖北省	武汉	8351	374	362	2020-02-05 23:52:29.021	2020-02-05
6642	湖北省	武汉	10117	455	414	2020-02-06 20:28:31.381	2020-02-06
3601	湖北省	武汉	11618	542	478	2020-02-07 22:01:50.311	2020-02-07
1070	湖北省	武汉	13603	747	545	2020-02-08 22:02:50.042	2020-02-08
357	湖北省	武汉	14982	877	608	2020-02-09 11:02:34.652	2020-02-09

用 **updateDate** 检索单日数据

In [119]:
```
daily_frm[daily_frm['updateDate'] == pd.to_datetime('2020-01-27')]
```

Out[119]:

	provinceName	cityName	confirmed	cured	dead	updateTime	updateDate
23384	上海市	嘉定区	1	0	0	2020-01-27 15:56:40.534	2020-01-27
23374	上海市	外地来沪人员	23	3	0	2020-01-27 15:56:40.534	2020-01-27
23385	上海市	奉贤区	1	0	0	2020-01-27 15:56:40.534	2020-01-27
23383	上海市	宝山区	1	0	0	2020-01-27 15:56:40.534	2020-01-27
23378	上海市	徐汇区	3	0	0	2020-01-27 15:56:40.534	2020-01-27
...	...	...	...	...	...	...	...
23877	黑龙江省	哈尔滨	8	0	0	2020-01-27 09:10:03.105	2020-01-27
23878	黑龙江省	大庆	5	0	0	2020-01-27 09:10:03.105	2020-01-27
23880	黑龙江省	牡丹江	1	0	0	2020-01-27 09:10:03.105	2020-01-27
23879	黑龙江省	绥化	3	0	1	2020-01-27 09:10:03.105	2020-01-27
23881	黑龙江省	齐齐哈尔	1	0	0	2020-01-27 09:10:03.105	2020-01-27

317 rows × 7 columns

用 **utils.add_dailyNew()** 加入每日新增确诊、死亡、治愈人数

In [120]:
```
daily_frm = utils.add_dailyNew(daily_frm)
```

In [121]:
```
daily_frm[daily_frm['cityName'] == '武汉'][['confirmed', 'dailyNew_confirmed',
'dead', 'dailyNew_dead', 'cured', 'dailyNew_cured', 'updateDate']][:5]
```

Out[121]:

	confirmed	dailyNew_confirmed	dead	dailyNew_dead	cured	dailyNew_cured	updateDate
26350	495	NaN	23	NaN	31	NaN	2020-01-24
25175	572	77.0	38	15.0	32	1.0	2020-01-25
24526	618	46.0	45	7.0	40	8.0	2020-01-26
23347	698	80.0	63	18.0	42	2.0	2020-01-27
22543	1590	892.0	85	22.0	47	5.0	2020-01-28

3.2 时序比较图 utils.tsplot_conf_dead_cured()

全国累计确诊、每日新增确诊、死亡、治愈时间序列图

In [122]:
```
fig = utils.tsplot_conf_dead_cured(daily_frm, title_prefix='全国')
plt.show()
```

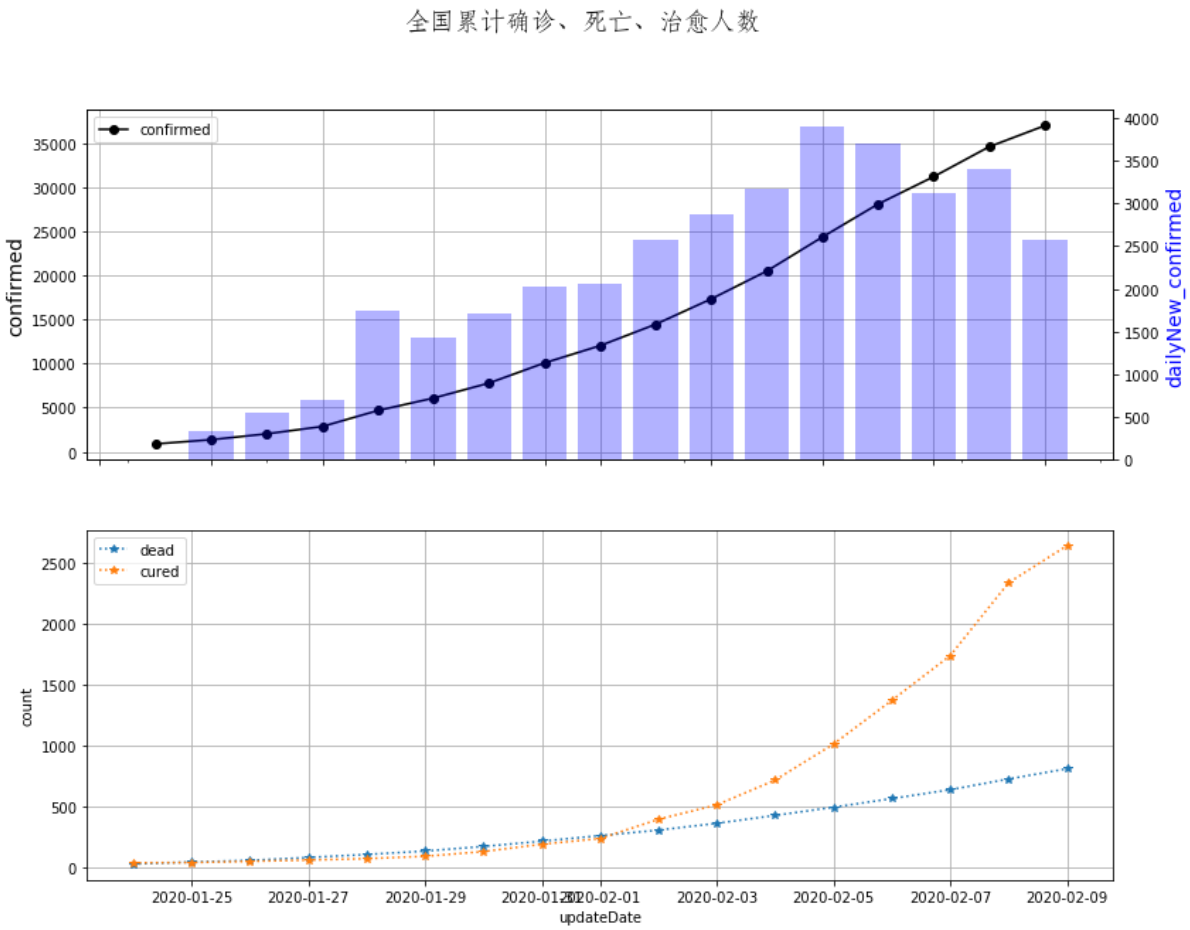

单个省份的时间序列也很容易，只要把想要的省份数据检索出来作为输入就可以了

In [123]:
```
province = '湖北省'    # 输入你所要的省份
fig = utils.tsplot_conf_dead_cured(daily_frm[daily_frm['provinceName'] == prov
ince], title_prefix=province)
plt.show()
```

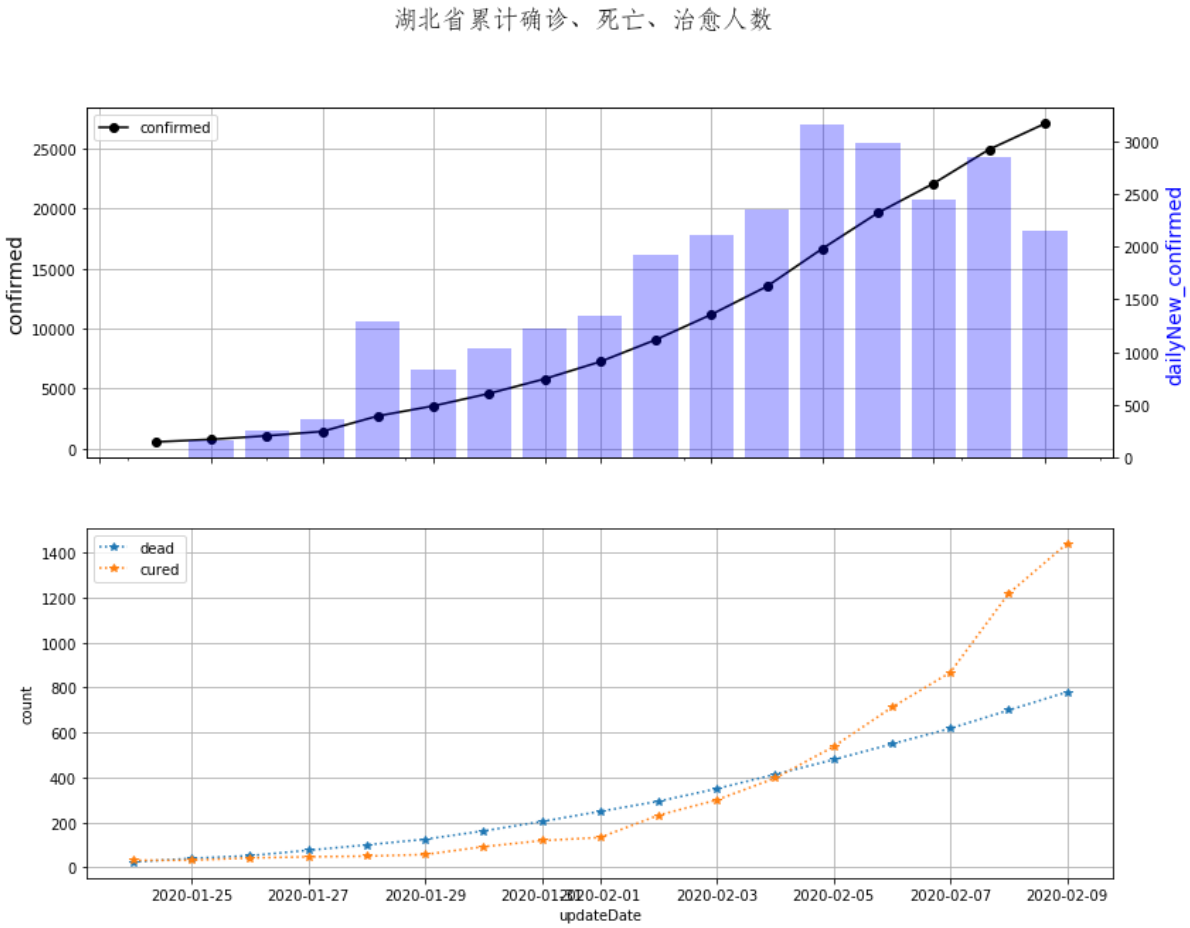

单个城市用法也是一样的，还可以使用 **logy=True** 画指数图，看人数是否指数增长

In [124]:
```
city = '武汉'
fig = utils.tsplot_conf_dead_cured(daily_frm[daily_frm['cityName'] == city], t
itle_prefix=city, logy=True)
plt.show()
```

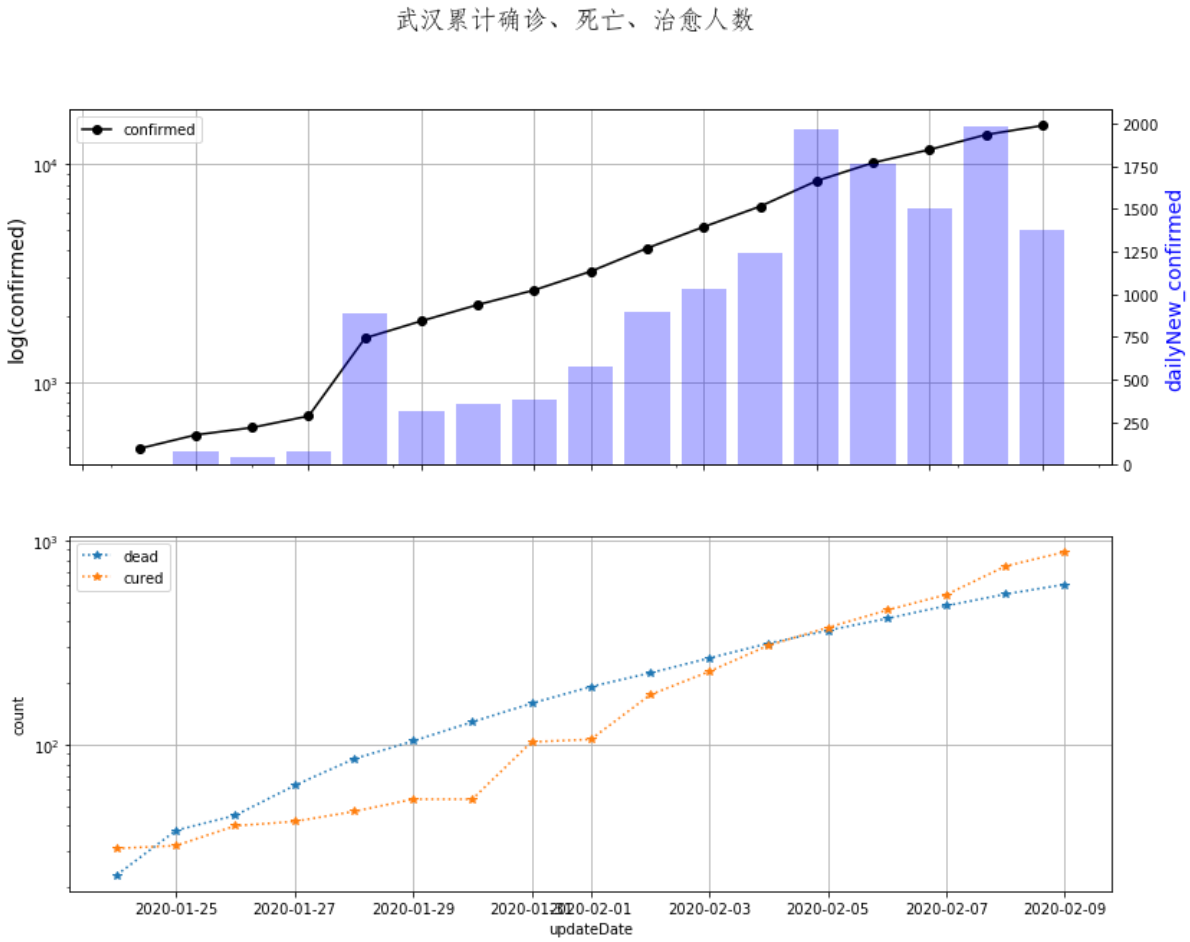

3.3 横向比较图 utils.cross_sectional_bar()

各省份在2月三号确诊数比较

In [125]:
```
utils.cross_sectional_bar(daily_frm, '2020-02-03', col='confirmed', groupby='provinceName', title='各省确累计诊数比较')
```

Out[125]: <matplotlib.axes._subplots.AxesSubplot at 0x2668b9ab3c8>

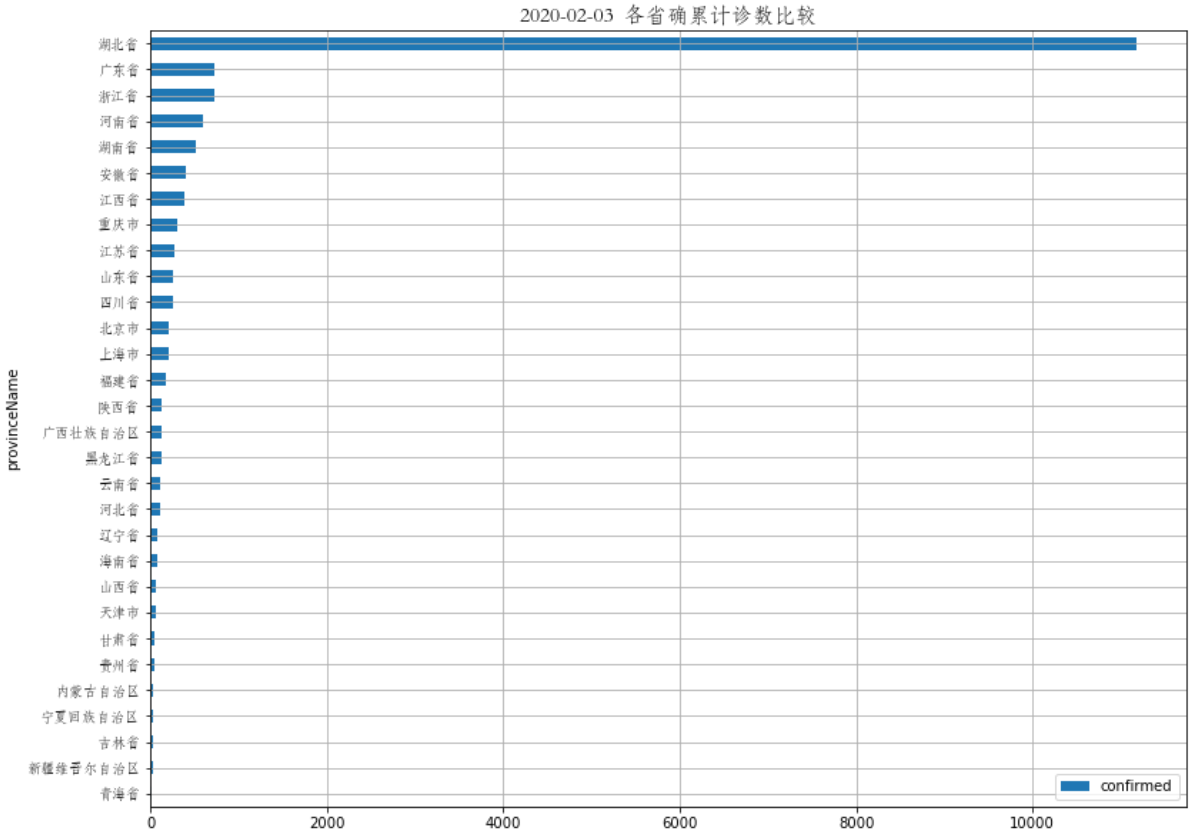

湖北省各地**2**月**1**号死亡数比较

In [126]:
```
utils.cross_sectional_bar(daily_frm[daily_frm['provinceName'] == '湖北省'], '2020-02-01', col='dead',
                          groupby='cityName', title='湖北各地累计死亡人数比较')
```

Out[126]: <matplotlib.axes._subplots.AxesSubplot at 0x2668aea0cf8>

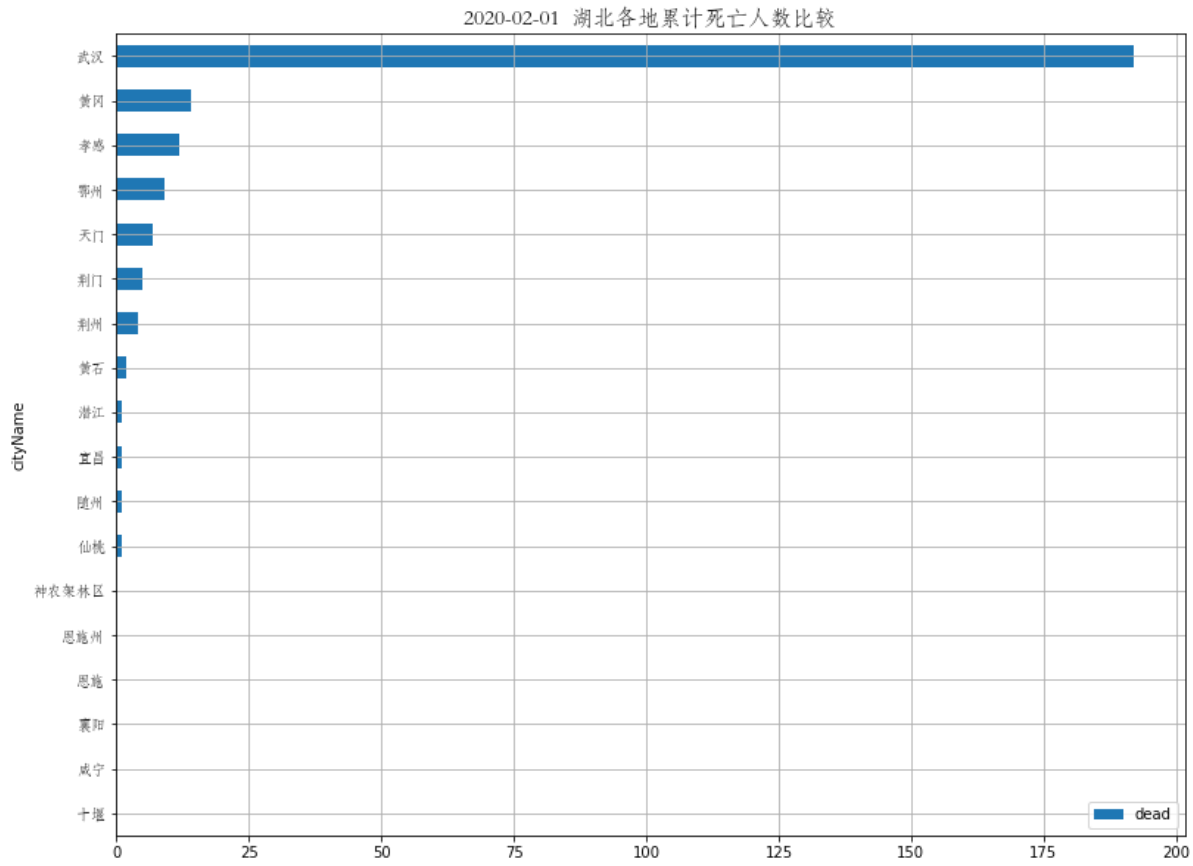

全国**2**月**5**日新增确诊最多的十个城市 （用 **largestN** 参数限制横条数目）

In [127]:
```
utils.cross_sectional_bar(daily_frm, '2020-02-05', col='dailyNew_confirmed',
                          groupby='cityName', title='全国各市新增确诊人数前十', la
rgestN=10)
```

Out[127]: <matplotlib.axes._subplots.AxesSubplot at 0x2668aea0eb8>